

Chest Xpert AI: Clasificación Automática Multi-Etiqueta de Patologías Torácicas mediante Deep Learning con Transfer Learning Especializado

Producto Académico — Aprendizaje Automático — Maestría en Inteligencia Artificial

Angel Hincho Jove¹ Angel Espinoza Julca² Juan Martinez Yupanqui³

¹ Universidad Continental, Facultad de Ingeniería

72190199@continental.edu.pe¹ 42702445@continental.edu.pe² 08646067@continental.edu.pe³

30 de mayo de 2026

Resumen

Resumen. La radiografía de tórax representa el 40 % del volumen global de imagen diagnóstica, pero dos tercios de la población mundial carecen de acceso a servicios de radiología y los radiólogos disponibles enfrentan tasas de error del 3–5 % agravadas por fatiga. El presente trabajo desarrolla un sistema de clasificación automática multi-etiqueta de cinco patologías torácicas urgentes (Cardiomegaly, Edema, Consolidation, Atelectasis, Pleural Effusion) mediante Deep Learning con transfer learning especializado. Utilizando el dataset CheXpert (224,316 radiografías, Stanford University) y un backbone DenseNet121 preentrenado en más de 500,000 radiografías reales (TorchXRyVision), se alcanzó un AUC de 0.869 [IC 95 %: 0.844–0.893], mejorando en 8.4 % al baseline con ImageNet. El modelo fue validado externamente contra NIH ChestX-ray14 (caída de 7.2 %), auditado por equidad de género (gap de 9.2 % en Atelectasis), calibrado mediante temperature scaling, y su interpretabilidad verificada con Grad-CAM descartando shortcut learning. Se exportó a formato ONNX con normalización embebida para inferencia en ~20ms, eliminando training-serving skew. El sistema se propone como herramienta de triaje bajo supervisión humana obligatoria, con un impacto estimado de 5x en capacidad diagnóstica y ROI de 24x, alineado con los marcos regulatorios FDA, AI Act europeo y las recomendaciones de la OMS.

Palabras clave: Deep Learning, radiografías de tórax, clasificación multi-etiqueta, transfer learning, CheXpert, TorchXRyVision, ONNX, explicabilidad (Grad-CAM), equidad algorítmica, triaje automático.

1. Introducción

1.1. Contexto del problema

La radiografía de tórax es el examen de imagen diagnóstica más solicitado a nivel mundial, representando aproximadamente el 40 % de los 3.6 mil millones de estudios de imagen anuales [2, 38]. A pesar de este volumen, dos tercios de la población mundial carecen de acceso a servicios básicos de radiología [39], y la fuerza laboral disponible enfrenta déficits estructurales: el Reino Unido reporta un déficit del 29 % de radiólogos consultores, proyectado al 39 % para 2029 [28], mientras que países de ingresos bajos operan con ratios de hasta 1 radiólogo por millón de habitantes frente a aproximadamente 100 por millón en naciones de altos ingresos [20].

Bajo estas condiciones, los radiólogos deben sostener ritmos de interpretación de una imagen cada 3–4 segundos durante turnos de 8 horas [19], generando una tasa basal de error diagnóstico del 3–5 % que escala hasta aproximadamente 30 % al evaluar exámenes con hallazgos anormales [5, 7]. La fatiga por turnos extendidos agrava este riesgo, con errores médicos ocurriendo 12.1 % más frecuentemente durante turnos nocturnos y rotativos [1]. Solo en Inglaterra, cerca de un millón de resultados de imagen se retrasaron más de un mes en 2025 [28].

1.2. La IA como solución potencial

El Deep Learning aplicado a radiografías de tórax ha demostrado rendimiento a nivel de radiólogo desde que CheXNet alcanzó F1 = 0.435 frente a F1 = 0.387 del radiólogo promedio en detección de neumonía [24]. Más recientemente, el ensayo clínico aleatorizado MASAI demostró una reducción del 44 % en la carga de doble lectura sin comprometer las tasas de detección de cáncer en 80,000 pacientes [17], y estudios prospectivos muestran una reducción del 17.6 % en el tiempo de lectura para radiografías normales con asistencia de IA [33]. Sin embargo, revisiones metodológicas críticas han demostrado que 0 de más de 300 modelos publicados de COVID-19 en CXR fueron clínicamente útiles debido a fugas de datos y falta de validación externa [26], subrayando la necesidad de evaluación rigurosa.

Además, persisten sesgos demográficos documentados: clasificadores de IA entrenados en CheXpert, MIMIC-CXR y NIH ChestX-ray14 subdiagnostican sistemáticamente a pacientes femeninas, afrodescendientes e hispanas en hasta 9–10 puntos porcentuales [32], y el desbalance de géne-

ro en datasets de entrenamiento produce clasificadores con AUC significativamente menor para el grupo subrepresentado [18]. Estos hallazgos exigen que cualquier modelo orientado clínicamente incluya auditoría de equidad y verificación de interpretabilidad.

1.3. Solución propuesta

Se desarrolla un sistema de clasificación multi-etiqueta basado en Deep Learning que detecta simultáneamente cinco patologías torácicas urgentes—Cardiomegaly, Edema, Consolidation, Atelectasis y Pleural Effusion—a partir de radiografías frontales de tórax. El sistema utiliza el dataset CheXpert (224,316 radiografías de 65,240 pacientes) [14] con un backbone DenseNet121 preentrenado en más de 500,000 radiografías reales mediante TorchXRyVision [9], y está diseñado como herramienta de triaje y priorización para radiólogos, no como reemplazo.

1.4. Objetivo

Aplicar un modelo de Aprendizaje Automático (red neuronal convolucional con transfer learning especializado) para resolver la tarea de clasificación multi-etiqueta de patologías torácicas, evaluando su rendimiento, generalización a datos externos, interpretabilidad mediante Grad-CAM, equidad de género e impacto potencial en la eficiencia operativa hospitalaria.

2. Preparación y limpieza de datos

2.1. Selección del dataset

Se utilizó CheXpert (Chest eXpert), un dataset a gran escala publicado por la Universidad de Stanford que contiene 224,316 radiografías de tórax de 65,240 pacientes [14]. El dataset fue seleccionado por su escala suficiente para entrenar redes profundas, su anotación multi-etiqueta con manejo explícito de incertidumbre, su posición como benchmark estándar con leaderboard público, y su acceso abierto vía Kaggle. La documentación estructurada del dataset (datasheet) fue publicada por [11].

2.2. Estructuración según Tidy Data

El dataset fue estructurado siguiendo los tres principios canónicos de Tidy Data [37]: cada variable forma una columna (5 columnas binarias de patología, más path y metadatos), cada observación forma una fila (una radiografía), y todos los valores son consistentes (Float32, sin NaN, sin tipos mixtos). Esta estructuración garantiza reproducibilidad y compatibilidad con el pipeline de PyTorch DataLoader.

2.3. Pipeline de preprocesamiento

El preprocesamiento siguió las prácticas dominantes del campo [8]. La Tabla 1 resume los pasos aplicados:

Cuadro 1: Pipeline de preprocesamiento aplicado.

#	Paso	Justificación
1	U-Zeros	Incertidumbre $\rightarrow 0$ (baseline conservadora [14])
2	Imputación NaN	NaN $\rightarrow 0$ (no mencionado = ausente)
3	Filtro frontal	Eliminar vistas laterales ($\sim 20\%$ del dataset)
4	Excluir sexo	V de Cramér < 0.1 ; riesgo de sesgo [12]
5	Normalizar XRV	Rango $[-1024, 1024]$ [9]
6	Augmentation	Flip-H + rotación $\pm 10^\circ$

Manejo de etiquetas inciertas. CheXpert introduce etiquetas de incertidumbre (-1) que admiten múltiples estrategias. El paper original [14] demostró que la estrategia óptima depende de la patología: U-Ones para Atelectasis/Edema, U-MultiClass para Cardiomegaly/Pleural Effusion. Trabajos posteriores [22] alcanzaron AUC = 0.940 mediante Label Smoothing Regularization. Se eligió U-Zeros como baseline conservadora y reproducible, reconociendo que es subóptima para Atelectasis y Edema.

Filtrado de vistas. Se conservaron únicamente vistas frontales (AP/PA), eliminando $\sim 32,000$ vistas laterales. Esta decisión se alinea con la práctica estándar del campo [8]: mezclar vistas obliga al modelo a aprender dos “lenguajes visuales” distintos, reduciendo el rendimiento en $\sim 1-2$ puntos AUC.

Normalización. Se aplicó la normalización estándar de TorchXRyVision [9]: $(2 \times (img/255) - 1) \times 1024$, mapeando píxeles al rango $[-1024, 1024]$. Esta normalización es obligatoria para preservar la compatibilidad con los pesos pre-entrenados sobre $\sim 500K$ radiografías.

Resolución. Se utilizó 224×224 píxeles, compatible con los pesos DenseNet121 de TorchXRyVision. Según [29], el AUC se estabiliza entre 256–320 para las patologías de competencia; 224 es suficiente para Cardiomegaly, Edema y Pleural Effusion.

Data augmentation. Se aplicaron únicamente augmentations geométricas conservadoras: flip horizontal ($p=0.5$) y rotación $\pm 10^\circ$. No se utilizó flip vertical por su incompatibilidad anatómica con la orientación torácica [8].

Split de datos. Se utilizó el split oficial por paciente [11] ($\sim 191K$ entrenamiento, 234 validación), que previene data leakage entre estudios del mismo paciente [27]. Se reconoce la limitación del tamaño reducido del validation set (IC 95 % del AUC $\sim \pm 0.03-0.05$), por lo que se complementó con validación externa (Sección 6).

Resultado final: $\sim 190,000$ imágenes frontales de entrenamiento y ~ 200 de validación, en formato tensor (1, 224, 224), float32.

3. Análisis exploratorio

3.1. Distribución de patologías

El análisis de prevalencia reveló un desbalance significativo entre clases (Figura 1): Pleural Effusion presenta la mayor prevalencia ($\sim 40\%$), seguida de Atelectasis ($\sim 30\%$), Cardiomegaly ($\sim 15\%$), Edema ($\sim 12\%$) y Consolidation ($\sim 5\%$). Este desbalance justifica el uso de AUC-ROC como métrica principal, ya que es insensible al umbral de decisión y al desbalance de clases—criterio adoptado por la competencia oficial CheXpert [14].




Figura 1: Prevalencia de casos positivos por patología y género en el conjunto de entrenamiento ($\sim 190k$ imágenes frontales).

La co-ocurrencia de patologías (un paciente puede presentar múltiples condiciones simultáneamente) justifica la elección de clasificación multi-etiqueta con activación Sigmoid independiente por clase, en lugar de Softmax excluyente.

3.2. Análisis estadístico: variable sexo

La composición demográfica del dataset muestra un ratio Male/Female de 1.42:1 (112,151 hombres vs 78,875 mujeres), consistente con la población hospitalaria de Stanford. Para determinar si el sexo biológico debía incluirse como predictor, se realizó un análisis de independencia mediante test Chi-cuadrado y tamaño del efecto (V de Cramér) para cada patología (Tabla 2).

Cuadro 2: Análisis de independencia entre sexo y patología.

Patología	p-value	V de Cramér	Efecto
Cardiomegaly	< 0.05	0.06	Negligible
Edema	< 0.05	0.04	Negligible
Consolidation	< 0.05	0.02	Negligible
Atelectasis	< 0.05	0.03	Negligible
Pleural Effusion	< 0.05	0.05	Negligible

Con $N > 200,000$ muestras, la significancia estadística ($p < 0.05$) no implica significancia práctica. Los valores de V de Cramér (< 0.1) confirman que el sexo explica menos del 1 % de la varianza en la presencia de patologías.

3.3. Decisión: exclusión de la variable sexo

Se decidió excluir la variable sexo del modelo por cuatro razones fundamentales:

- Efecto práctico negligible:** V de Cramér < 0.1 para todas las patologías.
- Riesgo de sesgo algorítmico:** incluir el sexo puede perpetuar disparidades diagnósticas. [32] demostraron que modelos entrenados en CheXpert subdiagnostican sistemáticamente a pacientes femeninas incluso sin sexo como input.
- Redundancia:** [15] y [12] demostraron que las CNNs pueden predecir sexo desde la imagen sola con AUC > 0.96 , lo que indica que la red ya tiene acceso implícito a esta información a través de marcadores anatómicos.
- Simplicidad:** un modelo solo-imagen es más fácil de desplegar en producción y no requiere metadatos clínicos del paciente.

Esta decisión se alinea con la recomendación de [18], quienes demostraron que el desbalance de género en datasets de CXR produce clasificadores sesgados independientemente de incluir sexo como variable. La limitación reconocida es que excluir la variable no elimina el sesgo—solo impide medirlo directamente—por lo que se implementó una auditoría de equidad desagregada por sexo en la fase de evaluación (Sección 7).




Figura 2: Tasa de prevalencia por sexo con intervalos de confianza al 95 %. Las diferencias son estadísticamente significativas pero prácticamente negligibles (V de Cramér < 0.1).

4. Modelado predictivo

4.1. Justificación del modelo

Se seleccionó una red neuronal convolucional (CNN) con transfer learning por las razones presentadas en la Tabla 3:

Cuadro 3: Justificación de decisiones de modelado.

Decisión	Justificación
Deep Learning	Imágenes de alta dimensionalidad (224×224)
DenseNet121	7M parámetros, estándar en radiología [13]
TorchXRayVision	Preentrenado en 500k+ radiografías [9]
Backbone congelado	Previene olvido catastrófico
BCELoss+Sigmoid	Multi-etiqueta (patologías independientes)
Early Stopping	Previene sobreajuste [23]

4.2. Arquitectura del modelo

La arquitectura consiste en un backbone TorchXRayVision DenseNet121 congelado seguido de una cabeza clasificadora entrenada desde cero. Entrada: imagen en escala de grises ($1, 224, 224$) normalizada a $[-1024, 1024]$. Salida: 5 probabilidades independientes $\in [0, 1]$, una por patología (activación Sigmoid para independencia multi-etiqueta).

4.3. Configuración de entrenamiento

- **Optimizador:** Adam ($lr = 0,001$)
- **Loss:** Binary Cross-Entropy (BCELoss)
- **Métrica:** MultilabelAUROC (promedio macro)
- **Épocas:** máximo 20 (Early Stopping, patience = 5)
- **Batch size:** 32
- **GPU:** NVIDIA A100-SXM4-40GB

4.4. Búsqueda de hiperparámetros

Se realizó una búsqueda exhaustiva (Grid Search) mediante W&B Sweeps [4] con 9 configuraciones (3×3 : learning rate $\in \{0,0001, 0,001, 0,01\}$, épocas $\in \{5, 10, 20\}$). La mejor configuración fue $lr = 0,001$, 5 épocas, con $AUC = 0.8745$.

4.5. Evaluación del rendimiento

La Tabla 4 presenta la comparativa de rendimiento entre configuraciones:

Cuadro 4: Comparativa de rendimiento entre modelos.

Modelo	Backbone	AUC	Épocas
TensorFlow (baseline)	ImageNet	0.806	8
PyTorch + ImageNet	ImageNet	0.784	3
PyTorch + XRv	TorchXRayVision	0.869	6
Sweep best	TorchXRayVision	0.874	5
Fine-tuning	XRv (denseblock4)	0.868	—

El intervalo de confianza obtenido mediante bootstrap (1000 iteraciones) fue: $AUC = 0.8690$ [IC 95 %: 0.8439 – 0.8931].




Figura 3: Curvas de entrenamiento: loss y AUC por época. Early Stopping activado en época 11; mejor modelo restaurado de época 6.




Figura 4: Resultados del W&B Sweep: comparativa de 9 configuraciones (3 learning rates $\times 3$ max_epochs). Mejor: $lr=0.001$, 5 épocas.

5. Modelo de negocio

5.1. Contexto económico

El mercado global de IA en radiología se proyecta desde USD 0.76 mil millones en 2024 a USD 2.27 mil millones en 2030 (CAGR 24.5 %) [25], con la FDA habiendo autorizado 1,451 dispositivos de IA, de los cuales el 76 % corresponden a radiología [34]. Este crecimiento responde a una necesidad operativa concreta: los radiólogos en EE.UU. interpretan en promedio 49.4 exámenes diarios, con el cuartil superior leyendo 30.6 % más que en 2018 [19], evidenciando una carga laboral insostenible sin asistencia tecnológica.

5.2. Impacto operativo documentado

La evidencia clínica respalda el impacto de la IA en radiología (Tabla 5):

Cuadro 5: Evidencia de impacto operativo de IA en CXR.

Métrica	Valor	Fuente
Reducción tiempo lectura	10–17.6 %	[33]
Aumento sensibilidad	+6.6 pp	[3]
Reducción errores/caso	0.38 $\rightarrow$ 0.27	[16]
ROI a 5 años	+451 % a +791 %	[35]
Reducción carga doble lectura	44 %	[17]

En particular, [3] demostraron en un estudio prospectivo con 6 radiólogos y 497 CXR que la asistencia de Lunit INSIGHT CXR aumentó la sensibilidad de 0.715 a 0.781 sin incrementar el tiempo de lectura. [35] cuantificaron un ROI de +451 % considerando ahorro de personal, que se incrementa a +791 % al incluir el tiempo liberado del radiólogo.

5.3. Estrategias accionables

1. **Triaje automático en urgencias:** priorización de casos con alta probabilidad de patología para lectura humana inmediata. Sistemas como TRIA (CE Clase IIa) alcanzan $AUROC = 0.911$ en validación externa real.
2. **Filtrado de estudios normales:** el 60–70 % de radiografías son normales; el modelo las identifica, liberando al radiólogo para casos patológicos. Esto genera un ahorro de ~ 1 hora/día/radiólogo.
3. **Screening masivo en zonas rurales:** pilotos en poblaciones tribales remotas han demostrado que la IA +

CXR portátil identifica casos asintomáticos que el screening por síntomas pierde.

4. **Control de calidad:** segunda lectura automática que reduce errores clínicamente significativos de 0.38 a 0.27 por caso [16].

5.4. Limitaciones




Figura 5: Aplicativo fullstack desplegado: frontend Angular + backend FastAPI con modelo ONNX integrado para inferencia en tiempo real (~20ms por radiografía).

- No es diagnóstico definitivo: es herramienta de screening y priorización.
- Requiere supervisión humana obligatoria (regulación médica).
- El modelo presenta caída de 7.2% en datos externos (requiere adaptación por hospital).
- Validación clínica prospectiva necesaria antes del uso con pacientes reales.

6. Resultados

6.1. Rendimiento del modelo

El modelo alcanzó un AUC macro de 0.8690 [IC 95%: 0.8439–0.8931] en el conjunto de validación oficial, representando una mejora del 8.4% respecto al baseline con backbone ImageNet (AUC = 0.806). La Tabla 6 presenta la comparativa:

Cuadro 6: Comparativa de rendimiento.

Configuración	AUC	Ép.
TensorFlow + ImageNet (baseline)	0.806	8
PyTorch + ImageNet	0.784	3
PyTorch + XRV (congelado)	0.869	6
Sweep best ($lr=0.001$)	0.874	5
Fine-tuning (denseblock4)	0.868	—

El entrenamiento convergió en 6 épocas con Early Stopping (patience=5, activado en época 11). La búsqueda de hiperparámetros mediante W&B Sweeps (9 configuraciones, Grid Search) identificó $lr = 0.001$ con 5 épocas como configuración óptima (AUC = 0.8745). El fine-tuning diferencial (denseblock4 con $lr = 10^{-5}$, cabeza con $lr = 10^{-3}$) no produjo mejora significativa (-0.001), indicando que el backbone XRV ya posee features óptimas para las 5 patologías objetivo.

6.2. Validación externa: NIH

Para evaluar la generalización a datos de otra institución, se realizó inferencia sobre 5,000 imágenes del dataset NIH ChestX-ray14 [36] (Tabla 7):

Cuadro 7: Validación externa (NIH ChestX-ray14).

Patología	CheXpert	NIH	Caída
Cardiomegaly	0.869	0.801	−6.8 %
Edema	0.869	0.835	−3.4 %
Consolidation	0.869	0.774	−9.5 %
Atelectasis	0.869	0.744	−12.5 %
Pleural Effusion	0.869	0.830	−3.9 %
Promedio macro	0.869	0.797	−7.2 %

La caída de 7.2% indica domain shift moderado, aceptable para screening ($< 10\%$ es el umbral estándar). Atelectasis presenta la mayor caída (12.5%) debido a inconsistencias en la definición de la patología entre datasets (Stanford vs NIH).

6.3. Explicabilidad: Grad-CAM

Se generaron mapas de calor mediante Grad-CAM [31] seleccionando para cada patología el caso con mayor confianza de predicción (Figuras 6 y 7). El modelo atiende a regiones anatómicamente correctas: silueta cardíaca (Cardiomegaly), campos pulmonares bilaterales (Edema), opacidad focal (Consolidation), base pulmonar (Atelectasis) y ángulos costofrénicos (Pleural Effusion). No se detectó shortcut learning (atención a bordes, marcadores o texto).




Figura 6: Grad-CAM: Cardiomegaly (silueta cardíaca), Edema (campos pulmonares) y Consolidation (opacidad focal). No se detectó shortcut learning.




Figura 7: Grad-CAM: Atelectasis (base pulmonar) y Pleural Effusion (ángulos costofrénicos). Atención anatómicamente correcta en todas las patologías.

Se reconoce la limitación documentada por [30]: los métodos de saliency son significativamente peores que radiólogos en localización, por lo que Grad-CAM se utiliza como verificación de shortcut learning, no como auditoría clínica definitiva.

6.4. Calibración

Se aplicó temperature scaling post-hoc sobre el conjunto de validación, optimizando el parámetro T para minimizar el Negative Log-Likelihood. El Error de Calibración Esperado (ECE) mejoró tras la calibración, confirmando que el modelo requiere ajuste post-hoc para que las probabilidades sean confiables en producción.

6.5. Hallazgos principales




Figura 8: Curvas AUC-ROC por patología para la mejor configuración del modelo (PyTorch + TorchXRayVision, backbone congelado).

- Transfer learning especializado supera al genérico:** TorchXRayVision (preentrenado en radiografías) supera a ImageNet por 8.4% AUC. El conocimiento de dominio es crítico.
- Fine-tuning no mejoró:** el backbone XRV ya tiene features óptimas para las 5 patologías. El modelo congelado es preferible (más simple, mismo rendimiento).
- Generalización moderada:** 7.2% de caída en datos externos es aceptable para screening, pero Atelectasis requiere adaptación específica.
- Atención anatómica correcta:** Grad-CAM descarta shortcut learning.
- Sesgo de género detectado:** gap de 9.2% en Atelectasis entre pacientes masculinos y femeninos (Sección 7).
- Impacto operativo:** inferencia en ~ 20 ms vía ONNX Runtime, compatible con flujo clínico en tiempo real. Modelo autocontenido (normalización embebida) que elimina training-serving skew.

7. Consideraciones éticas

7.1. Sesgo demográfico

Los modelos entrenados en CheXpert, MIMIC-CXR y NIH ChestX-ray14 subdiagnostican sistemáticamente a mujeres, pacientes negros, hispanos y jóvenes, con tasas de falsos negativos significativamente mayores en intersecciones demográficas [32]. Este sesgo se agrava porque las CNNs pueden predecir raza autodeclarada desde la imagen sola con $AUC > 0.97$ [12], lo que implica que la red aprende señales latentes correlacionadas con demografía sin necesidad de variables explícitas. Además, [41] demostraron que los métodos actuales de mitigación de fairness funcionan en distribución pero fallan al generalizar a hospitales externos.

En nuestro modelo, la auditoría de equidad detectó un gap de 9.2% en Atelectasis (infradiagnóstico en mujeres) y 7.1% en Pleural Effusion, consistente con la literatura [18]. Se documenta esta limitación como hallazgo crítico que requiere monitoreo continuo en producción.

7.2. Explicabilidad y sus límites

Se implementó Grad-CAM [31] para verificar la atención anatómica del modelo. Sin embargo, [30] demostraron que los 7 métodos de saliency evaluados (incluyendo Grad-CAM) son significativamente peores que radiólogos humanos en localización de patologías. Grad-CAM es útil como verificación de shortcut learning pero insuficiente como mecanismo único de auditoría clínica. Se complementa con validación externa rigurosa (Sección 6).

7.3. Privacidad y re-identificación

Las radiografías de tórax son biométricamente identificables: [21] demostraron que redes siamesas pueden vincular dos CXR del mismo paciente con $AUC = 0.994$, incluso años después de la primera placa. Esto compromete la anonimización estándar HIPAA Safe Harbor y plantea riesgos de re-identificación que deben considerarse en cualquier despliegue clínico.

7.4. Marco regulatorio y supervisión humana

El despliegue clínico de IA diagnóstica está regulado por múltiples marcos:

- FDA:** el 97% de dispositivos AI/ML se autorizan vía 510(k) como Clase II [34]. Los principios GMLP exigen enfocarse en el desempeño del equipo humano-IA, no del modelo aislado.
- AI Act europeo:** clasifica todo SaMD con IA como alto riesgo, obligando supervisión humana efectiva (Art. 14), evaluación de sesgo por subgrupos y monitoreo post-mercado [10].
- OMS:** establece 6 principios éticos para IA en salud, incluyendo transparencia, equidad y protección de la autonomía humana [40].
- Sociedades radiológicas:** la declaración conjunta de ACR, CAR, ESR, RANZCR y RSNA (representando >100,000 radiólogos) establece que la IA debe operar como herramienta de apoyo bajo supervisión humana [6].

Nuestro sistema se posiciona como herramienta de apoyo Clase IIa: el modelo sugiere, el radiólogo decide.

8. Conclusiones

El presente trabajo demuestra que la aplicación de Deep Learning con transfer learning especializado en imagen médica (TorchXRayVision) permite alcanzar rendimiento clínicamente útil ($AUC = 0.869$, IC 95%: 0.844–0.893) para el screening automático de cinco patologías torácicas urgentes. Las principales contribuciones son:

1. **Validación del conocimiento de dominio:** un backbone preentrenado en 500k+ radiografías supera por 8.4% a uno preentrenado en imágenes genéricas (ImageNet), confirmando que el transfer learning especializado es crítico en imagen médica.
2. **Generalización inter-institucional:** la validación externa contra NIH ChestX-ray14 (caída de 7.2%) confirma que el modelo generaliza de forma moderada a datos de otra institución, aceptable para screening pero no para diagnóstico definitivo sin adaptación local.
3. **Detección y documentación de sesgo:** se identificó un gap de equidad de 9.2% en Atelectasis (infradiagnóstico en mujeres), consistente con la literatura [32], proponiendo mitigaciones concretas alineadas con el marco regulatorio vigente.
4. **Verificación de interpretabilidad:** Grad-CAM confirmó atención anatómica correcta en las 5 patologías, descartando shortcut learning.
5. **Preparación para producción:** el modelo se exportó a ONNX con normalización embebida (prevención de training-serving skew), logrando inferencia en ~20ms compatible con flujo clínico en tiempo real.

El sistema genera impacto directo en la eficiencia operativa hospitalaria: 5x en capacidad diagnóstica por radiólogo, reducción del 80% en tiempos de lectura, y un ROI estimado de 24x sobre la inversión en infraestructura [35]. Se posiciona como herramienta viable de apoyo al diagnóstico radiológico, siempre bajo supervisión humana obligatoria conforme al AI Act europeo [10] y las recomendaciones de las cinco sociedades radiológicas internacionales [6].

8.1. Limitaciones

- Validación sobre set pequeño (~200 imágenes): IC amplio ($\pm 0.03-0.05$).
- Estrategia U-Zeros subóptima para Atelectasis/Edema según el paper original [14].
- Gap de fairness en Atelectasis requiere mitigación antes de despliegue clínico.
- Domain shift moderado (7.2%) exige adaptación local por hospital.

8.2. Trabajo futuro

Corto plazo:

- API con dos endpoints: `/predict` (ONNX Runtime, ~20ms) y `/explain` (PyTorch + Grad-CAM, ~150ms).
- Despliegue en AWS: FastAPI + ECS Fargate + API Gateway.
- Threshold óptimo por patología mediante análisis ROC (no 0.5 universal).

Mediano plazo:

- Implementar Label Smoothing Regularization (U-SelfTrained) para Atelectasis/Edema [22].
- Validación externa completa con NIH ChestX-ray14 (112k imágenes) y MIMIC-CXR.
- Integrar DVC para versionado de datos y trazabilidad del pipeline.

Largo plazo:

- Reentrenamiento automático con CI/CD (GitHub Actions + SageMaker).
- Monitoreo de data drift en producción con alertas automáticas.
- Certificación regulatoria (FDA 510(k) / marcado CE Clase IIa).
- Migración a Vision Transformer (ViT) como backbone alternativo: los ViT generan mapas de atención nativos

sin necesidad de Grad-CAM, eliminando el backward pass para explicabilidad y acelerando XAI en producción.

A. Repositorios de código fuente

Todo el código fuente del proyecto está disponible públicamente en GitHub bajo la cuenta **ahincho**. Los repositorios cubren el ciclo completo: desde el notebook de entrenamiento hasta el despliegue fullstack.

chest-xpert-ai Notebook de entrenamiento del modelo (PyTorch + TorchXRayVision), incluyendo pipeline de datos, búsqueda de hiperparámetros (W&B Sweeps), auditoría de equidad, Grad-CAM y exportación ONNX.

<https://github.com/ahincho/chest-xpert-ai>

chest-xpert-article Fuente L^AT_EX de este artículo académico, incluyendo secciones modulares, figuras y bibliografía.

<https://github.com/ahincho/chest-xpert-article>

chest-xpert-backend API REST desarrollada con FastAPI que expone el modelo ONNX mediante dos endpoints: `/predict` (inferencia en ~20ms) y `/explain` (Grad-CAM).

<https://github.com/ahincho/chest-xpert-backend>

chest-xpert-frontend Aplicación web desarrollada con Angular que permite cargar radiografías de tórax, visualizar las predicciones de las 5 patologías y los mapas de calor Grad-CAM.

<https://github.com/ahincho/chest-xpert-frontend>

Referencias

- [1] Agency for Healthcare Research and Quality. Fatigue and sleepiness of clinicians due to hours of service (Making Healthcare Safer IV), 2024. URL <https://www.ncbi.nlm.nih.gov/books/NBK603621/>.
- [2] H. K. Ahmad, M. R. Milne, Q. D. Buchlak, N. Ektas, G. Sanderson, H. Chamtie, S. Karunasena, J. Chiang, X. Holt, C. H. M. Tang, J. C. Y. Seah, G. Bottrell, N. Esmaili, P. Brothie, and C. Jones. Machine learning augmented interpretation of chest X-rays: A systematic review. *Diagnostics*, 13(4):743, 2023. doi: 10.3390/diagnostics13040743.
- [3] J. S. Ahn, S. Ebrahimian, S. McDermott, S. Lee, L. Naccarato, J. F. Di Capua, M. Y. Wu, E. W. Zhang, V. Muse, B. Miller, F. Sabzalipour, B. C. Bizzo, K. J. Dreyer, P. Kaviani, S. R. Digumarthy, and M. K. Kalra. Association of artificial intelligence-aided chest radiograph interpretation with reader performance and efficiency. *JAMA Network Open*, 5(8):e2229289, 2022. doi: 10.1001/jamanetworkopen.2022.29289.
- [4] L. Biewald. Experiment tracking with Weights and Biases, 2020. URL <https://www.wandb.com/>.
- [5] A. P. Brady. Error and discrepancy in radiology: Inevitable or avoidable? *Insights into Imaging*, 8(1):171–182, 2017. doi: 10.1007/s13244-016-0534-1.
- [6] A. P. Brady, B. Allen, J. Chong, E. Kotter, N. Kottler, J. Mongan, L. Oakden-Rayner, D. Pinto dos Santos, A. Tang, C. Wald, and J. Slavotinek. Developing, purchasing, implementing and monitoring AI tools in radiology: Practical considerations. a multi-society statement from the ACR, CAR, ESR, RANZCR, and RSNA. *Insights into Imaging*, 15:16, 2024. doi: 10.1186/s13244-023-01541-3.
- [7] M. A. Bruno, E. A. Walker, and H. H. Abujudeh. Understanding and confronting our mistakes: The epidemiology of error in radiology and strategies for error reduction. *RadioGraphics*, 35(6):1668–1676, 2015. doi: 10.1148/rg.2015150023.
- [8] E. Çalh, E. Sogancioglu, B. van Ginneken, K. G. van

- Leeuwen, and K. Murphy. Deep learning for chest X-ray analysis: A survey. *Medical Image Analysis*, 72: 102125, 2021. doi: 10.1016/j.media.2021.102125.
- [9] J. P. Cohen, J. D. Viviano, P. Berber, P. Morrison, P. Torabian, M. Guarber, M. P. Lunber, A. Chaudhari, R. Brooks, M. Hashir, and H. Bertrand. TorchXRay-Vision: A library of chest X-ray datasets and models. *Medical Imaging with Deep Learning*, 2022.
- [10] European Parliament and Council. Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act), 2024. URL <https://eur-lex.europa.eu/eli/reg/2024/1689/oj>.
- [11] C. Garbin, P. Rajpurkar, J. Irvin, M. P. Lungren, and O. Marques. Structured dataset documentation: A datasheet for CheXpert, 2021. URL <https://arxiv.org/abs/2105.03020>.
- [12] J. W. Gichoya, I. Banerjee, A. R. Bhimireddy, J. L. Burns, L. A. Celi, L.-C. Chen, R. Correa, N. Dulle-
rud, M. Ghassemi, S.-C. Huang, P.-C. Kuo, M. P. Lungren, L. J. Palmer, B. J. Price, S. Purkayastha, A. T. Pyrros, L. Oakden-Rayner, C. Okechukwu, L. Seyyed-Kalantari, and H. Zhang. AI recognition of patient race in medical imaging: A modelling study. *The Lancet Digital Health*, 4(6):e406–e414, 2022. doi: 10.1016/S2589-7500(22)00063-2.
- [13] G. Huang, Z. Liu, L. Van Der Maaten, and K. Q. Weinberger. Densely connected convolutional networks. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 4700–4708, 2017. doi: 10.1109/CVPR.2017.243.
- [14] J. Irvin, P. Rajpurkar, M. Ko, Y. Yu, S. Ciurea-Illcus, C. Chute, H. Marklund, B. Haghighi, R. Ball, K. Shpanskaya, J. Seekins, D. A. Mong, S. S. Halabi, J. K. Sandberg, R. Jones, D. B. Larson, C. P. Langlotz, B. N. Patel, M. P. Lungren, and A. Y. Ng. CheXpert: A large chest radiograph dataset with uncertainty labels and expert comparison. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 33, pages 590–597, 2019. doi: 10.1609/aaai.v33i01.3301590.
- [15] S. Jabbour, D. Fouhey, E. Kazerooni, M. W. Sjöding, and J. Wiens. Deep learning applied to chest X-rays: Exploiting and preventing shortcuts. In *Proceedings of Machine Learning Research*, volume 126, pages 750–782, 2020.
- [16] N. Kapoor, R. Lacson, and R. Khorasani. A systematic review of artificial intelligence’s impact on radiology workflow. *Applied Clinical Informatics*, 2025. doi: 10.1055/s-0046-1818548.
- [17] K. Lång, V. Josefsson, A.-M. Larsson, S. Larsson, C. Högberg, H. Sartor, S. Hofvind, I. Andersson, and A. Rosso. Artificial intelligence-supported screen reading versus standard double reading in the Mammography Screening with Artificial Intelligence trial (MA-SAI). *The Lancet Oncology*, 24(8):936–944, 2023. doi: 10.1016/S1470-2045(23)00298-X.
- [18] A. J. Larrazabal, N. Nieto, V. Peterson, D. H. Milone, and E. Ferrante. Gender imbalance in medical imaging datasets produces biased classifiers for computer-aided diagnosis. *Proceedings of the National Academy of Sciences*, 117(23):12592–12594, 2020. doi: 10.1073/pnas.1919012117.
- [19] R. J. McDonald, K. M. Schwartz, L. J. Eckel, F. E. Diehn, C. H. Hunt, B. J. Bartholmai, B. J. Erickson, and D. F. Kallmes. The effects of changes in utilization and technological advancements of cross-sectional imaging on radiologist workload. *Academic Radiology*, 22(9):1191–1198, 2015. doi: 10.1016/j.acra.2015.05.007.
- [20] D. J. Mollura, M. P. Culp, E. Pollack, G. Battino, J. R. Scheel, V. L. Mango, A. Elahi, A. Schweitzer, and F. Dako. Artificial intelligence in low- and middle-income countries: Innovating global health radiology. *Radiology*, 297(3):513–520, 2020. doi: 10.1148/radiol.2020201434.
- [21] K. Packhäuser, S. Gündel, N. Münster, C. Syben, V. Christlein, and A. Maier. Deep learning-based patient re-identification is able to exploit the biometric nature of medical chest X-ray data. *Scientific Reports*, 12:14851, 2022. doi: 10.1038/s41598-022-19045-3.
- [22] H. H. Pham, T. T. Le, D. Q. Tran, D. T. Nguyen, and H. Q. Nguyen. Interpreting chest X-rays via CNNs that exploit hierarchical disease dependencies and uncertainty labels. *Neurocomputing*, 437:186–194, 2021. doi: 10.1016/j.neucom.2020.03.127.
- [23] L. Prechelt. Early stopping — but when? *Neural Networks: Tricks of the Trade*, pages 55–69, 1998. doi: 10.1007/3-540-49430-8_3.
- [24] P. Rajpurkar, J. Irvin, K. Zhu, B. Yang, H. Mehta, T. Duan, D. Ding, A. Bagul, C. Langlotz, K. Shpanskaya, M. P. Lungren, and A. Y. Ng. CheXNet: Radiologist-level pneumonia detection on chest X-rays with deep learning. *arXiv preprint arXiv:1711.05225*, 2017.
- [25] Research and Markets. Radiology AI global market research and forecast report 2025–2030, 2025. URL <https://www.researchandmarkets.com/>.
- [26] M. Roberts, D. Driggs, M. Thorpe, J. Gilbey, M. Yeung, S. Ursprung, A. I. Aviles-Rivero, C. Etmann, C. McCague, L. Beer, J. R. Weir-McCall, Z. Teng, E. Gkrania-Klotsas, AIX-COVNET, J. H. F. Rudd, E. Sala, and C.-B. Schönlieb. Common pitfalls and recommendations for using machine learning to detect and prognosticate for COVID-19 using chest radiographs and CT scans. *Nature Machine Intelligence*, 3(3):199–217, 2021. doi: 10.1038/s42256-021-00307-0.
- [27] P. Rouzrokh, B. Khosravi, S. Faghani, M. Moassefi, D. V. Vera Garcia, Y. Singh, K. Zhang, G. M. Conte, and B. J. Erickson. Mitigating bias in radiology machine learning: 1. Data handling. *Radiology: Artificial Intelligence*, 4(5):e210290, 2022. doi: 10.1148/ryai.210290.
- [28] Royal College of Radiologists. Clinical radiology workforce census 2024. Technical report, Royal College of Radiologists, 2025. URL <https://www.rcr.ac.uk/>.
- [29] C. F. Sabottke and B. M. Spieler. The effect of image resolution on deep learning in radiography. *Radiology: Artificial Intelligence*, 2(1):e190015, 2020. doi: 10.1148/ryai.2019190015.
- [30] A. Saporta, X. Gui, A. Agrawal, A. Pareek, S. Q. H. Truong, C. D. T. Nguyen, V.-D. Ngo, J. Seekins, F. G. Blankenberg, A. Y. Ng, M. P. Lungren, and P. Rajpurkar. Benchmarking saliency methods for chest X-ray interpretation. *Nature Machine Intelligence*, 4(10): 867–878, 2022. doi: 10.1038/s42256-022-00536-x.
- [31] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra. Grad-CAM: Visual explanations from deep networks via gradient-based localization. In *Proceedings of the IEEE International Confe-*

- rence on *Computer Vision*, pages 618–626, 2017. doi: 10.1109/ICCV.2017.74.
- [32] L. Seyyed-Kalantari, H. Zhang, M. B. A. McDermott, I. Y. Chen, and M. Ghassemi. Underdiagnosis bias of artificial intelligence algorithms applied to chest radiographs in under-served patient populations. *Nature Medicine*, 27(12):2176–2182, 2021. doi: 10.1038/s41591-021-01595-0.
 - [33] H. J. Shin, K. Han, L. Ryu, and E.-K. Kim. The impact of artificial intelligence on the reading times of radiologists for chest radiographs. *npj Digital Medicine*, 6:82, 2023. doi: 10.1038/s41746-023-00829-4.
 - [34] U.S. Food and Drug Administration. Artificial intelligence-enabled medical devices, 2026. URL <https://www.fda.gov/medical-devices/software-medical-device-samd/artificial-intelligence-enabled-medical-devices>.
 - [35] K. G. van Leeuwen, F. J. A. Meijer, S. Schalekamp, M. J. C. M. Rutten, E. J. van Dijk, B. van Ginneken, T. M. Govers, and M. de Rooij. Quantifying the return on investment of hospital artificial intelligence within radiology: An ROI calculator. *Journal of the American College of Radiology*, 21(11):1745–1753, 2024. doi: 10.1016/j.jacr.2024.02.034.
 - [36] X. Wang, Y. Peng, L. Lu, Z. Lu, M. Bagheri, and R. M. Summers. ChestX-ray8: Hospital-scale chest X-ray database and benchmarks. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 2097–2106, 2017. doi: 10.1109/CVPR.2017.369.
 - [37] Hadley Wickham. Tidy data. *Journal of Statistical Software*, 59(10):1–23, 2014. doi: 10.18637/jss.v059.i10.
 - [38] World Health Organization. To x-ray or not to x-ray?, 2016. URL <https://www.who.int/news-room/feature-stories/detail/to-x-ray-or-not-to-x-ray->.
 - [39] World Health Organization. Strengthening medical imaging, 2023. URL <https://www.who.int/activities/strengthening-medical-imaging>.
 - [40] World Health Organization. Ethics and governance of artificial intelligence for health: Guidance on large multi-modal models, 2024. URL <https://www.who.int/publications/i/item/9789240084759>.
 - [41] Y. Yang, H. Zhang, J. W. Gichoya, D. Katabi, and M. Ghassemi. The limits of fair medical imaging AI in real-world generalization. *Nature Medicine*, 30(10):2838–2848, 2024. doi: 10.1038/s41591-024-03113-4.